# Introduction à la Science des données

# Travail pratique 06 - EDA, Clustering et apprentissage non-supervisé

Professeurs: Carlos Peña et Stephan Robert

Assistant(s): Thibault Schowing, Xavier Brochet

# Emails: prenom.nom@heig-vd.ch

Date:

**Modalités** • Travail individuel.

• 17-19 janvier 2023

- Ordinateur et cours autorisé • Utilisez ce notebook ainsi que votre cours pour répondre aux questions.
- Vous pouvez modifier / ajouter / supprimer ce que vous voulez dans ce notebook, il n'est pas à rendre.
- Note

• Le notebook est volontairement dépourvu au maximum de texte. C'est à vous de comprendre le code!

• Ce TP est noté sur 6, pour un poids de 10%

In [2]:

TP6 - Partie 1

## TP6 - Partie 2

Clustering d'image de couleur

Vous pouvez trouver les graphiques principaux sur cette page. Le plot 3D se trouve tout en bas et est interactif.

### import matplotlib.pyplot as plt import matplotlib.image as image

import numpy as np

```
from skimage import io
        from sklearn.cluster import KMeans
In [3]:
        # Lire l'image
        #img = io.imread('./imgs/parrot-3017449 640.jpg')
        img = io.imread('https://lemagdesanimaux.ouest-france.fr/images/dossiers/2020-04/lori-1-134153.jpg')
```

```
print(img.shape)
         img = img[:,:,:3] # On a besoin que de 3 canaux (RGB). Nécessaire si l'image a 4 canaux
        ax = plt.axes(xticks=[],yticks=[])
        ax.imshow(img)
        (400, 650, 3)
        <matplotlib.image.AxesImage at 0x1bcf9a73b50>
Out[3]:
```

In [4]: img.shape (400, 650, 3)

```
In [5]:
         img_data = (img / 255.).reshape(-1, 3) # Valeurs entre 0 et 1
         img data.shape # On a une liste, composée de listes de 3 valeurs
        (260000, 3)
Out[5]:
       Plot 3D
In [6]:
        fig = plt.figure(figsize=(20,20))
```

ax.scatter(img\_data[:,0], img\_data[:,1], img\_data[:,2], c=img\_data, s=0.01)

<mpl\_toolkits.mplot3d.art3d.Path3DCollection at 0x1bcfa2d0e50>

ax = fig.add\_subplot(projection='3d')

self.colors = colors

if self.colors is None:

self.colors = self.img data

rand = np.random.RandomState(42)

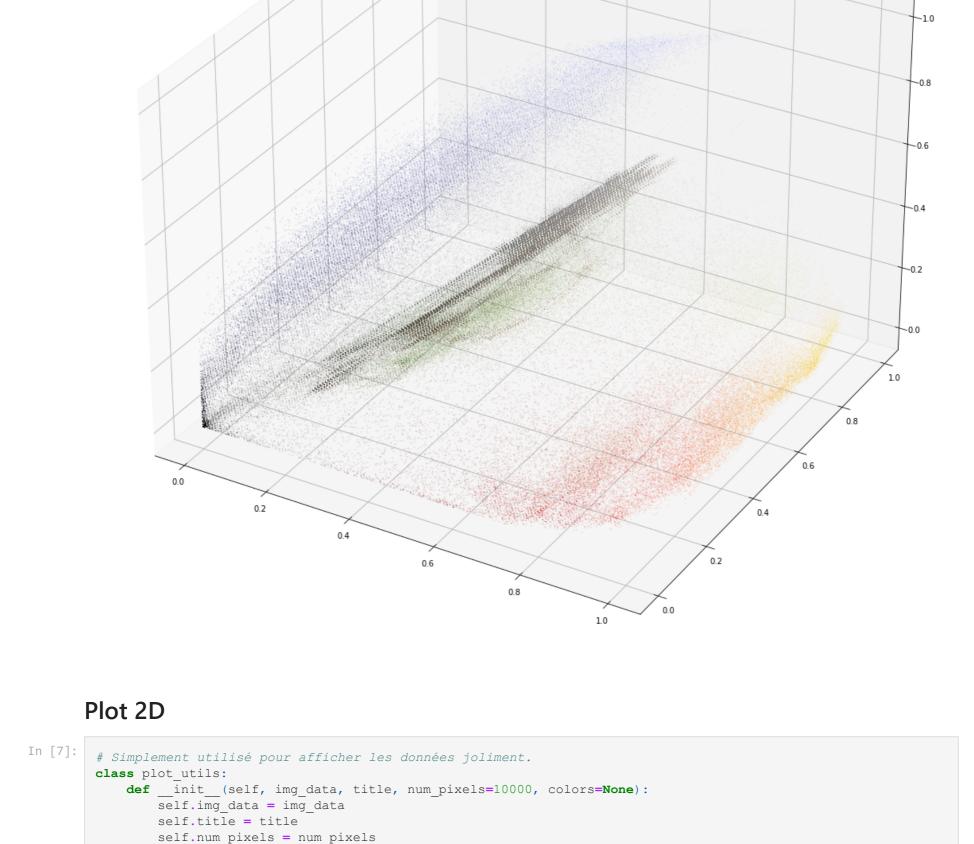
def colorSpace(self):

0.6

Green

Out[4]:

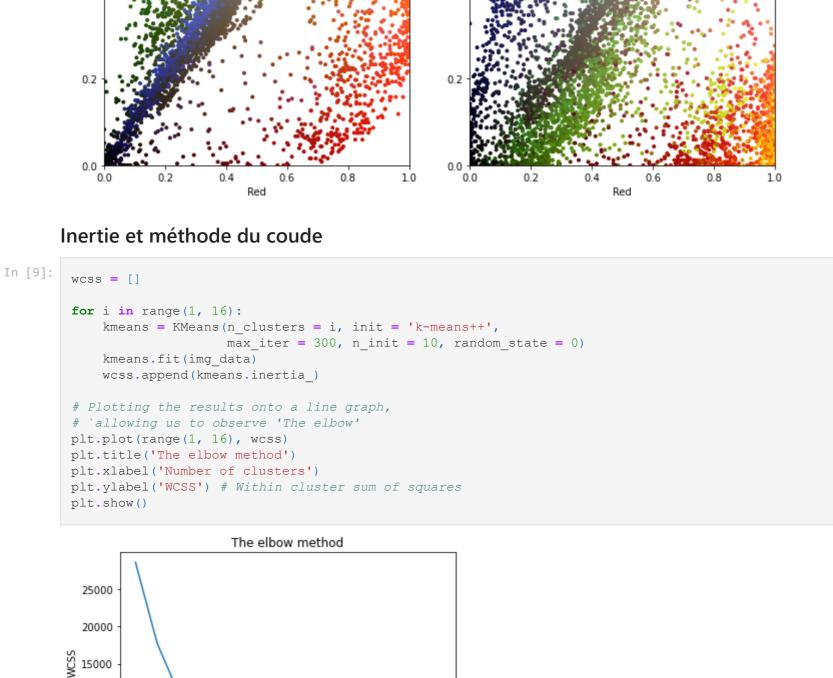
Out[6]:



```
index = rand.permutation(self.img_data.shape[0])[:self.num_pixels]
                colors = self.colors[index]
                R, G, B = self.img data[index].T
                fig, ax = plt.subplots(1, 2, figsize=(12,8))
                ax[0].scatter(R, G, color=colors, marker='.')
                ax[0].set(xlabel='Red', ylabel='Green', xlim=(0, 1), ylim=(0, 1))
                ax[1].scatter(R, B, color=colors, marker='.')
                ax[1].set(xlabel='Red', ylabel='Blue', xlim=(0, 1), ylim=(0, 1))
                fig.suptitle(self.title, size=20)
In [8]:
        color = plot_utils(img_data, title='Original possible colors')
        color.colorSpace()
                                       Original possible colors
         1.0
                                                         1.0
          0.8
                                                         0.8
```

0.6

Blue



12

y = plot\_utils(img\_data, colors=k\_colors, title="Reduced color space: K colors")

14

Reduced color space: K colors

1.0

```
5000
                            Number of clusters
```

kmeans = KMeans(n\_clusters=K).fit(img\_data)

10000

y.colorSpace()

1.0

In [10]:

In [11]:

In [12]:

ax2.set\_xticks([]) ax2.set\_yticks([]) ax2.imshow(k\_img)

plt.show()

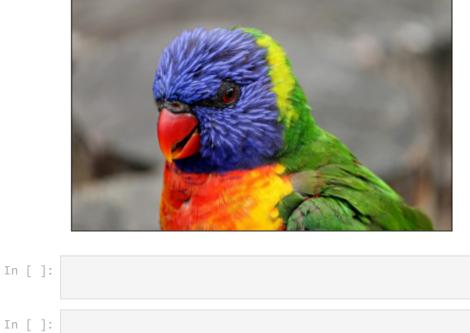
plt.subplots\_adjust(top=0.85)

```
0.6
```

 $\verb|k_colors = kmeans.cluster_centers_[kmeans.predict(img_data)]| \textit{ #here we are predicting K colors on the img}|$ 

```
0.8
                                                          0.8
Green
  0.4
k_img = np.reshape(k_colors, (img.shape))
 \textit{fig, } (\texttt{ax1, ax2}) = \texttt{plt.subplots}(\texttt{1, 2,figsize=(15,6)}) \textit{\#this show 1 row but 2 col means one row has 2 images } \\ 
fig.suptitle('K-means Clustering (Dominant colors Extraction)', fontsize=18)
ax1.set_title('Original')
ax1.set_xticks([])
ax1.set_yticks([])
ax1.imshow(img)
ax2.set_title('Compressed')
```

# K-means Clustering (Dominant colors Extraction)



Original

